Informe metodológico: SkillMatch, clasificación de vacantes por habilidades

Willer Rivero Marriaga, Luis Amaya, Jesús, Andrés y Luis Reyes

Fundación Universitaria Tecnológico Comfenalco

Minería de Datos I - Proyecto de Aula

C. C. Cuadrado Beltrán

13 de octubre de 2026

Informe metodológico: SkillMatch, clasificación de vacantes por habilidades

SkillMatch es una plataforma pensada para Cartagena que conecta a estudiantes y recién egresados con empresas, con el propósito de reducir el desempleo juvenil. En lugar de mirar solo los años de experiencia, la plataforma muestra en cada vacante un porcentaje de compatibilidad calculado con las habilidades, los proyectos y las evidencias académicas de la persona.

Para este trabajo se tomó una pregunta que aporta una base de datos al proyecto: ¿las habilidades que pide una vacante permiten predecir su categoría laboral, y cuáles se asocian más con cada categoría? El objetivo del análisis es comprobar, con datos y un modelo ejecutado, que las habilidades contienen información suficiente para distinguir vacantes, que es el supuesto sobre el cual se apoya el porcentaje de compatibilidad.

El proyecto todavía no cuenta con datos reales de usuarios ni de vacantes (los registros de la base de datos eran simulados). Por eso se siguió la situación C de la guía del docente (Cuadrado Beltrán, s. f.): buscar un conjunto de datos público relacionado con el problema, sin cambiar de proyecto. El código del proyecto se encuentra en el repositorio de jesuscastilla-cloud (2026).

Fuente y descripción de los datos

Se usó el archivo `all_job_post.csv` del conjunto *job-skill-set* de Kaggle (Mutlu, 2024), derivado de *LinkedIn job postings* (Arshkon, s. f.) y publicado bajo licencia CC BY-SA 4.0. Contiene 1.167 vacantes con cinco columnas: identificador (`job_id`), categoría (`category`), título, descripción y lista de habilidades (`job_skill_set`).

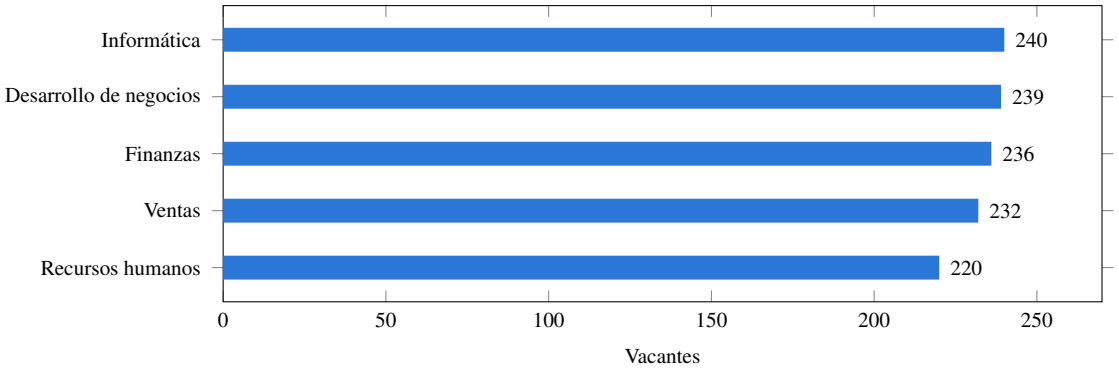
La variable objetivo es la categoría, que tiene cinco clases casi balanceadas (ver Figura 1). Las habilidades son el predictor: hay 4.984 habilidades distintas, pero la mayoría aparece en muy pocas vacantes.

Alcance y límites

Las ofertas están en inglés y provienen de LinkedIn; el archivo no incluye ubicación, así que no se puede afirmar que representen el mercado laboral de Cartagena. Las habilidades las extrajo una herramienta automática del texto de cada oferta.

Figura 1

Número de vacantes por categoría



Nota. Total de 1.167 vacantes. Elaboración propia con datos de Mutlu (2024).

Conjunto descartado

Antes de elegir este archivo se revisó *Job market skills dataset* (sharmagayatri, s. f.), que reúne 1.000 ofertas obtenidas con la API de Adzuna. Se descartó porque ninguna fila trae salario, 925 de las 1.000 ofertas son de una sola categoría (informática) y casi todas son de India. Un modelo entrenado ahí habría acertado el 92,5 % respondiendo siempre «informática», sin aprender nada.

Metodología y uso de MinedApp

El trabajo se organizó en dos herramientas complementarias. En Google Colab (Python, pandas, scikit-learn, matplotlib y seaborn) se construyó, ejecutó y evaluó el modelo oficial (McKinney, 2010; Pedregosa et al., 2011). En MinedApp (s. f.) se recorrieron las seis etapas de la guía con una versión compacta de los datos, para documentar las decisiones y generar el reporte (ver Tabla 1).

Código generado frente a modelo ejecutado

El código que genera MinedApp no se tomó como resultado: se probó con los datos antes de usarlo. En la etapa 3 el código tenía un error (`NameError`, porque la palabra `category` aparecía sin comillas dentro de `select_dtypes`) y se corrigió. Los resultados oficiales de este informe salen del cuaderno de Colab, ejecutado de principio a fin.

Tabla 1

Etapas recorridas en MinedApp

Etapa	Qué se hizo en MinedApp
1. Problema	Proyecto SkillMatch, tarea de clasificación, variable objetivo `category`.
2. Datos	Carga del archivo `dataset_vacantes_minedapp_top30.csv`: 1.167 filas, 31 columnas (`category` y las 30 habilidades más frecuentes en 0/1), sin valores nulos.
3. Preprocesamiento	Sin tratamiento de nulos, *outliers* ni escalado, porque no había nulos y todas las variables son 0/1. *Label Encoding* para la variable objetivo.
4. Modelado	Regresión logística, 20 % de prueba, semilla 42.
5. Evaluación	Exactitud, precisión, *recall*, F1 y matriz de confusión.
6. Reporte	Descarga del reporte en Markdown, completado con los resultados reales de Colab.

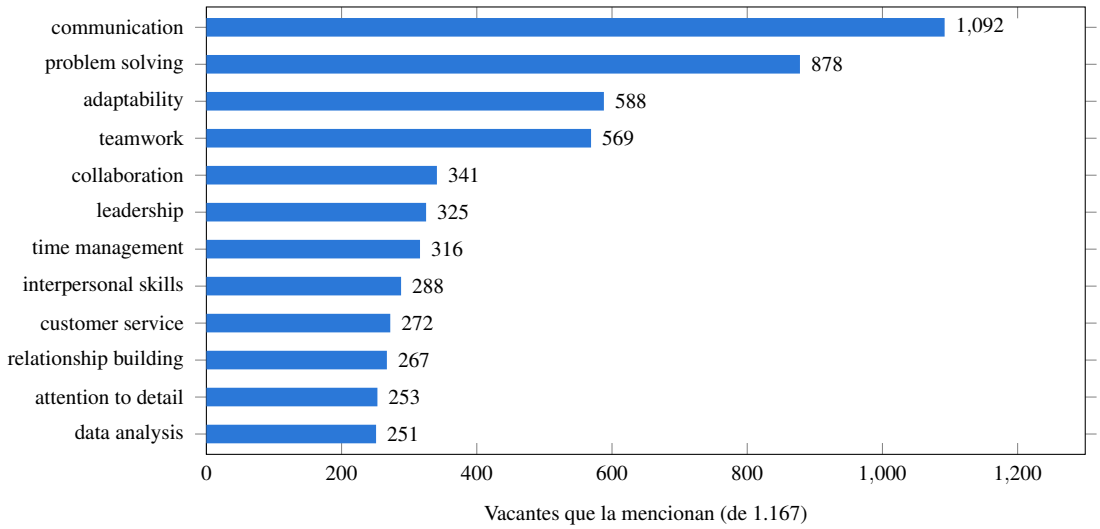
Exploración y preparación

Calidad de los datos

No hay valores faltantes, ni duplicados por identificador, ni por título y descripción. Cada vacante tiene entre 5 y 43 habilidades (en promedio, 17,9). Las habilidades más frecuentes son transversales (comunicación, resolución de problemas, adaptabilidad, trabajo en equipo) y aparecen en todas las categorías (ver Figura 2); por ejemplo, comunicación está en entre el 91 % y el 95 % de las vacantes de cada categoría, por lo que ayuda poco a distinguirlas.

Figura 2

Las 12 habilidades más frecuentes en todo el conjunto



Nota. Elaboración propia con datos de Mutlu (2024).

Decisiones de preparación y por qué

- Se descartaron `job_id` (solo identifica), el título y la descripción. El título delata la categoría («HR Manager»), y se quería medir cuánto distinguen las habilidades por sí solas.
- Las habilidades se pasaron a minúsculas y se eliminaron repetidas dentro de cada vacante, para que «Communication» y «communication» cuenten como la misma.
- Se dividió primero (80 % entrenamiento, 20 % prueba, estratificado, semilla 42) y recién después se eligieron las habilidades, usando solo el entrenamiento. Así la prueba no influye en qué variables se usan.
- Se conservaron las habilidades que aparecen en al menos 10 vacantes del entrenamiento (198 habilidades). Las demás son tan raras que no permiten aprender un patrón. Cada habilidad se representa con 1 si la vacante la pide y 0 si no.
- No se imputó, no se trataron atípicos y no se escaló: no había faltantes y todas las variables son 0/1. Aplicar esas técnicas solo para usarlas habría sido innecesario.

Modelo y evaluación

Modelo

Se usó regresión logística multiclase (máximo 1.000 iteraciones, semilla 42), con la categoría como variable objetivo y las 198 habilidades como variables predictoras. Se eligió por ser interpretable: cada coeficiente indica cuánto empuja una habilidad hacia una categoría. Como referencia se usó un modelo que siempre responde la categoría más frecuente.

Resultados en el conjunto de prueba

El conjunto de prueba tiene 234 vacantes. La Tabla 2 resume las medidas globales y la Tabla 3 las medidas por categoría.

Comparación de modelos y robustez

Con 234 vacantes de prueba, una sola división puede variar unos tres puntos por azar. Por eso se repitió la evaluación con validación cruzada de 5 pliegues sobre el entrenamiento y se compararon tres modelos (ver Tabla 4).

Tabla 2
Medidas globales en el conjunto de prueba

Medida	Valor
Exactitud del modelo de referencia	0,2051
Exactitud de la regresión logística	0,7308
F1 macro de la regresión logística	0,7346

Tabla 3
Precisión, recall y F1 por categoría

Categoría	Precisión	*Recall*	F1	Vacantes de prueba
Desarrollo de negocios	0,55	0,56	0,56	48
Finanzas	0,93	0,79	0,85	47
Recursos humanos	0,92	0,80	0,85	44
Informática	0,75	0,92	0,82	48
Ventas	0,58	0,60	0,59	47

Tabla 4
Comparación de modelos con validación cruzada de 5 pliegues

Modelo	Exactitud en validación cruzada (media)	Desviación	Exactitud en prueba
Regresión logística	0,7728	0,0271	0,7308
Naive Bayes (Bernoulli)	0,7792	0,0187	0,7650
Random Forest	0,7888	0,0256	0,7778

Los tres modelos quedan dentro de la variación esperada entre sí, así que se mantuvo la regresión logística porque permite explicar los resultados. También se probó el umbral de frecuencia de las habilidades con validación cruzada (ver Tabla 5).

Tabla 5
Exactitud según el umbral de frecuencia de las habilidades

Habilidades que deben aparecer en al menos	Habilidades usadas	Exactitud (validación cruzada)
5 vacantes	395	0,7793
10 vacantes (elegido)	198	0,7728
20 vacantes	109	0,7546
40 vacantes	63	0,7171

El umbral de 10 se fijó antes de comparar. Pasar a 5 mejora menos de un punto, dentro del margen de variación, a cambio de duplicar las variables; subir a 20 o 40 sí empeora.

Corrida de MinedApp

Con el archivo compacto (solo las 30 habilidades más frecuentes), el mismo modelo alcanzó una exactitud de 0,6624 y un F1 ponderado de 0,6661. Es menos que el modelo oficial (0,7308 con 198 habilidades), lo que indica que las habilidades menos frecuentes también aportan información para distinguir categorías. Esta cifra se presenta como comparación y no como resultado principal.

Resultados e interpretación

El modelo acierta aproximadamente tres de cada cuatro vacantes, frente a una de cada cinco del modelo de referencia, y esto se mantiene en la validación cruzada. Es decir, las habilidades sí contienen información que distingue categorías.

Dónde acierta y dónde falla

Finanzas, recursos humanos e informática se reconocen bien (F1 entre 0,82 y 0,85). La mayor parte de los errores, 35 de 63, confunde desarrollo de negocios con ventas (18 en un sentido y 17 en el otro): ambas categorías comparten habilidades como relaciones con clientes y CRM. Otros errores frecuentes son finanzas leídas como informática (8) y recursos humanos leídos como informática (5). La Figura 3 muestra la matriz de confusión completa.

Figura 3

Matriz de confusión del modelo oficial en el conjunto de prueba

Categoría real \ Categoría predicha	Desarrollo de negocios	Finanzas	Recursos humanos	Informática	Ventas
Desarrollo de negocios	27	1	1	1	18
Finanzas	2	37	0	8	0
Recursos humanos	2	1	35	5	1
Informática	1	1	1	44	1
Ventas	17	0	1	1	28

Nota. Total de 234 vacantes de prueba. Las filas corresponden a la categoría real y las columnas a la categoría predicha; el sombreado es más oscuro cuanto mayor es el número de vacantes.

Habilidades más asociadas con cada categoría

La Tabla 6 presenta las habilidades de mayor coeficiente en la regresión logística para cada categoría.

Tabla 6
Habilidades con mayor coeficiente en la regresión logística por categoría

Categoría	Habilidades con mayor coeficiente
Desarrollo de negocios	*business development, market research, lead generation, cold calling, networking*
Finanzas	*financial reporting, finance, financial analysis, financial modeling, accounting*
Recursos humanos	*hris, employee relations, confidentiality, human resources, onboarding*
Informática	*troubleshooting, information technology, active directory, network administration, jira*
Ventas	*sales management, sales, product knowledge, customer relationship management, retail experience*

Lo que esto significa para SkillMatch: las habilidades técnicas y específicas del área distinguen vacantes; las habilidades blandas que aparecen en casi todas las ofertas (comunicación, trabajo en equipo) casi no ayudan a diferenciarlas. Al calcular compatibilidad conviene darles más peso a las habilidades específicas y tratar con cuidado las comerciales, que se confunden entre sí.

Limitaciones y conclusiones

Qué no puede concluirse

- Los datos son vacantes en inglés tomadas de LinkedIn, sin información de ubicación. No se puede afirmar que los resultados valgan para Cartagena.
- Las habilidades fueron extraídas automáticamente de las descripciones y pueden tener errores u omisiones.
- Con 234 vacantes de prueba, las cifras pueden variar unos tres puntos por azar; por eso se incluyó la validación cruzada.
- Este análisis valida que las habilidades distinguen categorías de vacantes. No valida el porcentaje de compatibilidad de SkillMatch, que no se pudo evaluar porque la plataforma aún no tiene usuarios ni vacantes reales.

- El conjunto no incluye salario, por lo que no se hizo regresión de salario. Tampoco se usó información del DANE como dato del modelo: la tasa de desempleo juvenil de Cartagena sirve de contexto del problema, no de variable.

Dificultades encontradas

No existía un conjunto público de vacantes de Cartagena con habilidades; la base de datos del proyecto contenía datos simulados; el primer conjunto revisado no servía (sin salarios y con una categoría dominante); y el código que generó MinedApp en la etapa 3 tuvo un error que hubo que corregir.

Conclusión

Con un modelo sencillo y explicable se logró predecir la categoría de una vacante a partir de sus habilidades con una exactitud de 0,73 frente a 0,21 de la referencia, y se identificaron las habilidades más características de cada categoría.

Qué mejoraríamos en una siguiente versión

- Reunir vacantes reales de Cartagena (portales de empleo y el Servicio Público de Empleo) para repetir el análisis con datos locales y poder comparar.
- Incluir salario y experiencia requerida para estimar rangos salariales.
- Probar el modelo contra el cálculo de compatibilidad de la plataforma cuando existan usuarios reales.
- Agrupar o afinar las habilidades comerciales para reducir la confusión entre ventas y desarrollo de negocios.

Referencias

Arshkon. (s. f.). *LinkedIn job postings (2023-2024)* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/arshkon/linkedin-job-postings

Cuadrado Beltrán, C. C. (s. f.). *Guía práctica para completar los entregables del Proyecto de Aula, Minería de Datos I*.

jesuscastilla-cloud. (2026). *Skillmatch* [Repositorio de código]. GitHub. https://github.com/jesuscastilla-cloud/Skillmatch

McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt y J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56-61). https://doi.org/10.25080/Majora-92bf1922-00a

MinedApp. (s. f.). *Guía interactiva de minería de datos*. https://cr1085.github.io/minedApp/

Mutlu, B. (2024). *job-skill-set* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/batuhanmutlu/job-skill-set

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825-2830. https://jmlr.org/papers/v12/pedregosa11a.html

sharmagayatri. (s. f.). *Job market skills dataset* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/sharmagayatri/job-market-skills-dataset