Formato de propuesta del modelo predictivo

Minería de Datos I - Proyecto de Aula SkillMatch

A. Identificación

Nombre del proyecto	SkillMatch: plataforma local de conexión entre talento joven y empresas de Cartagena
Integrantes	Willer Rivero Marriaga (análisis de datos), Luis Amaya, Jesús, Andrés y Luis Reyes (documentación)
Repositorio	https://github.com/jesuscastilla-cloud/Skillmatch
Fecha	13 de octubre de 2026

B. Problema

¿Qué situación aborda el proyecto? SkillMatch busca ayudar a reducir el desempleo juvenil en Cartagena conectando a estudiantes y recién egresados con empresas según lo que saben hacer. Cada vacante muestra un porcentaje de compatibilidad que se calcula con las habilidades del candidato, sus proyectos y sus evidencias académicas.

¿Qué pregunta se busca responder? ¿Las habilidades que pide una vacante permiten predecir a qué categoría laboral pertenece (informática, desarrollo de negocios, finanzas, ventas o recursos humanos), y qué habilidades se asocian más con cada una?

¿Por qué sería útil estudiar esa situación mediante datos? Todo el motor de compatibilidad de SkillMatch parte de la idea de que las habilidades dicen algo real sobre una vacante. Antes de construir ese cálculo conviene comprobar con datos si las habilidades, por sí solas, distinguen unas vacantes de otras y cuáles son las más reveladoras.

C. Datos

Fuente y enlace	Kaggle, conjunto "job-skill-set" (Batuhan Mutlu, 2024), archivo all_job_post.csv. Se deriva de "LinkedIn Job Postings" (Arshkon, licencia CC BY-SA 4.0). https://www.kaggle.com/datasets/batuhanmutlu/job-skill-set
Registros y variables	1.167 vacantes y 5 columnas: job_id, category, job_title, job_description y job_skill_set.
Variables relevantes	job_skill_set: lista de habilidades de cada vacante. Hay 4.984 habilidades distintas; 198 aparecen en al menos 10 vacantes del conjunto de entrenamiento.
Variable objetivo	category, con 5 clases casi balanceadas: informática 240, desarrollo de negocios 239, finanzas 236, ventas 232 y recursos humanos 220.
Problemas de calidad	Sin valores faltantes ni duplicados. Las habilidades fueron extraídas automáticamente del texto de cada oferta y pueden tener ruido. Los datos están en inglés, no traen ubicación y provienen de LinkedIn, por lo que no se puede asegurar que representen el mercado de Cartagena.

Se evaluó y descartó otro conjunto (job_market_skills_dataset, 1.000 ofertas obtenidas con la API de Adzuna) porque ninguna de sus filas trae salario, el 92,5 % de las ofertas es de una sola categoría y casi todas son de India.

D. Modelo propuesto

Tipo de tarea	Clasificación multiclase (5 clases).

Algoritmo	Regresión logística.
Justificación	Es sencilla de explicar y sus coeficientes muestran qué habilidades empujan hacia cada categoría, que es justo lo que SkillMatch necesita entender. Se comparó con Naive Bayes y Random Forest para comprobar que no se sacrificaba rendimiento.
Variables predictoras	Presencia (1) o ausencia (0) de cada una de las 198 habilidades seleccionadas.
Estrategia de preparación	Se descartan job_id, el título y la descripción (el título delata la categoría). Las habilidades se pasan a minúsculas y sin repetir. Primero se divide en entrenamiento y prueba y después se eligen las habilidades usando solo el entrenamiento. No hubo nulos que imputar ni variables que escalar.
División de los datos	80 % entrenamiento (933 vacantes) y 20 % prueba (234), estratificada por categoría, semilla 42. Además, validación cruzada de 5 pliegues sobre el entrenamiento.

E. Evaluación

Métricas	Exactitud (accuracy), precisión, recall, F1 por categoría y F1 macro, y matriz de confusión.
Razón	Las 5 categorías están casi balanceadas, así que la exactitud es informativa. El F1 macro revela si alguna categoría se queda atrás y la matriz de confusión muestra en qué pares se equivoca el modelo.
Modelo de referencia	Responder siempre la categoría más frecuente (exactitud 0,2051).

F. Resultado esperado

Estado: el modelo ya fue construido, ejecutado y evaluado. El cuaderno de Google Colab, los archivos de resultados y el recorrido por MinedApp están en la carpeta mineria-datos del repositorio. Estos son resultados reales sobre las 234 vacantes de prueba:

Medida	Resultado
Modelo de referencia (exactitud)	0,2051
Regresión logística (exactitud)	0,7308
Regresión logística (F1 macro)	0,7346
Validación cruzada, regresión logística (media)	0,7728

¿Qué decisión podría apoyarse? Que las habilidades sí distinguen categorías de vacantes (finanzas, recursos humanos e informática se reconocen bien; ventas y desarrollo de negocios se parecen mucho). Esto respalda usar habilidades como base del porcentaje de compatibilidad y sugiere agrupar o afinar cómo se describen las habilidades comerciales.

¿Cuáles son las principales limitaciones? Los datos son ofertas en inglés de LinkedIn y no de Cartagena; las habilidades se extrajeron de forma automática; con 234 vacantes de prueba una cifra puede variar unos tres puntos por azar. Este análisis valida la idea de que las habilidades distinguen vacantes, pero no valida todavía el porcentaje de compatibilidad de la plataforma, que necesitará datos reales de usuarios y vacantes de la ciudad.